

Dimensionamento e Sequenciamento de Lotes de Produção de uma Indústria de Balões de Látex

17/03/2026

1 Introdução

1.1 Contextualização

2 Revisão de literatura

2.1 Planejamento hierárquico de produção

O planejamento de produção organiza-se em níveis de decisão com horizontes e granularidades distintos — estratégico, tático e operacional (ANTHONY, 1965). Decisões de nível superior fixam metas e restrições para o nível inferior; o nível inferior devolve ao superior o que de fato foi executado, fechando o ciclo.

Hax e Meal (1975) formalizam esse esquema para produção multi-planta sob demanda sazonal: um plano agregado de estoque por família de produtos é obtido por programação linear e desagregado, em seguida, em programações detalhadas por item através de regras clássicas de controle de estoque. Bitran e Hax (1977) generalizam a proposta: o problema é particionado em subproblemas por nível, cada um resolvido por um procedimento próprio, com mecanismos explícitos de agregação (de baixo para cima) e desagregação (de cima para baixo) conectando os níveis.

Esse padrão é a base dos sistemas avançados de planejamento (*Advanced Planning Systems*); Stadtler (2005) descreve a *Supply Chain Planning Matrix*, que posiciona módulos de planejamento por horizonte — longo, médio e curto prazo — e por função, entre produção, distribuição e vendas, sendo a referência corrente para separar decisão tática de decisão operacional.

A correspondência família→item de Hax e Meal mapeia diretamente o problema dos balões: formato e acabamento definem a família decidida no nível tático; a cor é o item desagregado no nível operacional. Essa fronteira não é uma escolha arbitrária de modelagem — ela coincide com a separação real entre os dois tipos de *setup* do processo produtivo: a troca de forma, custosa e decidida com semanas de antecedência, e a troca de cor, uma limpeza decidida dia a dia.

2.2 Dimensionamento de lotes capacitado

O dimensionamento de lotes (*lot sizing*) tem origem no modelo de Wagner e Whitin (1958), que resolve por programação dinâmica o tamanho de lote ótimo de um único item sob demanda determinística variável no tempo, sem restrição de capacidade. A versão capacitada — *Capacitated Lot Sizing Problem* (CLSP) — introduz um limite de capacidade por período e já é NP-difícil no caso de dois itens com *setups* independentes (BITRAN; YANASSE, 1982; CHEN; THIZY, 1990).

O CLSP é dito de *big-bucket*: cada período (tipicamente uma semana ou um mês) admite a produção de mais de um item, e a granularidade interna ao período não é modelada. Karimi, Fatemi Ghomi e Wilson (2003) revisam formulações e algoritmos exatos e heurísticos para essa classe. Jans e Degraeve (2008) cobrem extensões que aproximam o modelo de aplicações industriais — máquinas paralelas, múltiplos níveis de estrutura

de produto, *setups* dependentes de sequência. Buschkühl et al. (2010) classificam quatro décadas de abordagens de solução. Para o caso de item único, Brahimi et al. (2006, 2017) cobrem formulações e métodos de solução em dois levantamentos que, juntos, resumem a literatura até 2016.

O nível tático do problema dos balões é um CLSP em máquinas paralelas não relacionadas — produtividade p_{ij} distinta por par máquina-balão, compatibilidades próprias —, com venda perdida em vez de atraso (*backorder*) na camada de previsão de demanda, e sem custo de estoque explícito na função objetivo. Essa combinação, detalhada na Seção 2.5, é o que distingue o problema do CLSP canônico.

2.3 Dimensionamento e sequenciamento integrados

Quando o *setup* depende da sequência de produção — como ocorre na troca de cor — o *big-bucket* deixa de bastar: sem ordem definida dentro do período, não há como cobrar o *setup* certo. A literatura resolve isso fundindo tamanho de lote e sequenciamento num único modelo de *small-bucket*, com microperíodos dentro de cada período maior. O *General Lotsizing and Scheduling Problem* (GLSP), de Fleischmann e Meyr (1997), é uma das formulações canônicas dessa família. O *Capacitated Lot-sizing and Scheduling Problem with Sequence-Dependent setups* (CLSD), de Haase (1996), é a outra. Drexel e Kimms (1997) organizam a taxonomia completa de modelos *small-bucket*: o *Discrete Lot-sizing and Scheduling Problem* (DLSP), o *Continuous Setup Lotsizing Problem* (CSLP), o *Proportional Lotsizing and Scheduling Problem* (PLSP), além do GLSP e do CLSD já apresentados.

Um mecanismo central dessa literatura é o *setup carryover*: a configuração da máquina persiste entre períodos consecutivos sem pagar novo *setup*, desde que o mesmo item seja produzido em ambos. Sox e Gao (1999) introduzem o conceito para o CLSP; Suerie e Stadtler (2003) formalizam a versão com lotes ligados (*linked lot sizes*), permitindo que um lote atravessasse a fronteira de dois períodos sem interrupção. Copil et al. (2017) revisam e classificam toda essa família de modelos simultâneos de dimensionamento e sequenciamento; Guimarães, Klabjan e Almada-Lobo (2014) tratam especificamente da modelagem de *setups* dependentes de sequência dentro desses modelos.

A troca de cor no problema dos balões é um *setup* dependente de sequência e, além disso, direcional: a limpeza de claro para escuro é barata; de escuro para claro, cara. O carryover de estado — forma e cor montadas na máquina — atravessando dias e mesmo paradas é o mecanismo desta literatura reaproveitado no nível operacional diário do modelo proposto.

2.4 Aplicações em indústria de processo

Uma via alternativa para o dimensionamento e sequenciamento integrados evita inflar um único MILP (*Mixed-Integer Linear Programming*, programação linear inteira mista): decompõe o problema em dois módulos, um de quantidade e outro de sequência, ou resolve a sequência por regra e não por otimização exata. Essa abordagem é comum em indústrias de processo com estrutura de dois estágios, onde um insumo intermediário é preparado numa etapa e diferenciado — por sabor, cor ou aroma — numa etapa seguinte.

A indústria de bebidas é a aplicação mais estudada e mais próxima estruturalmente do problema dos balões: xarope preparado num tanque, envasado em seguida em diferentes sabores e tamanhos. Ferreira, Morabito e Rangel (2009, 2010) modelam esse problema de dois estágios — preparo do xarope e envase — com *setups* dependentes de sequência e de tempo, comparando estratégias de *relax-and-fix*; Toledo et al. (2012) resolvem a mesma classe de problema com algoritmos meméticos. A analogia com os balões é direta: composto pigmentado é o xarope, moldagem é o envase.

A indústria têxtil de fiação oferece uma analogia ainda mais próxima, porque acrescenta uma restrição de sincronização que a de bebidas não tem. Camargo, Toledo e Almada-Lobo (2014) tratam um problema de dois estágios em que uma mistura de fibras (*fiber blend*) alimenta múltiplas máquinas de fiação em paralelo; na formulação MSGSLSP (*Multi-Stage General Lot-sizing and Scheduling Problem*) que adotam, de Camargo, Toledo e Almada-Lobo (2012), todas as máquinas ativas num mesmo microperíodo devem processar fios da mesma família de mistura, sincronizadas por uma variável binária de qualidade. Essa restrição — só uma mistura disponível por vez, e todas as máquinas do segundo estágio precisam respeitá-la — é exatamente o que emergiria se a pigmentação do composto de látex fosse modelada como etapa própria, com múltiplas moldagens em paralelo consumindo o mesmo composto pigmentado corrente. Duas diferenças, porém, mantêm o problema dos balões fora dessa formulação: os autores tratam a troca de mistura como *setup* nulo (o oposto da troca de forma dos balões, que é o *setup* caro) e adotam atraso (*backorder*) com custo de estoque explícito, não venda perdida por custo de oportunidade.

Günther, Grunow e Neuhaus (2006) descrevem o *block planning*, aplicado originalmente à indústria de tintura de cabelo e depois generalizado para produção do tipo *make-and-pack*: a sequência de produção segue uma ordem fixa e pré-definida de variantes, tipicamente por contaminação crescente — do tom mais claro para o mais escuro —, evitando limpeza entre trocas. É a mesma lógica de sequenciamento por cor da moldagem de balões, com o mesmo argumento de fundo: claro antes de escuro minimiza limpeza.

2.5 Síntese e posicionamento

A Tabela 1 resume o problema dos balões frente às quatro classes revisadas. Nenhuma delas reúne, isolada, a combinação completa de características do problema; a contribuição está na interseção, não em qualquer elemento tomado sozinho.

Tabela 1 – Posicionamento do problema dos balões frente às classes revisadas (✓: presente; parcial: presente em parte; –: ausente)

	CLSP clássico	GLSP/CLSD	Bebidas	Fiação	Balões
Máquinas paralelas não relacionadas	✓	parcial	–	✓	✓
<i>Setup</i> dependente de sequência	–	✓	✓	✓	✓
<i>Setup</i> direcional (assimétrico)	–	parcial	–	–	✓
Dois tipos de <i>setup</i> , escalas distintas	–	–	parcial	–	✓
Venda perdida (sem <i>backorder</i>)	parcial	parcial	–	–	✓
Custo de oportunidade puro (sem <i>holding</i>)	–	–	–	–	✓
Previsão de demanda própria integrada	–	–	–	–	✓

Duas características do problema dos balões não têm equivalente direto na literatura revisada. A primeira é a perecibilidade do látex — recebimento diário, estoque em tanques —, uma restrição de matéria-prima incomum na literatura de CLSP, que em geral assume insumo disponível sob demanda. A segunda é a coexistência de dois tipos de *setup* em escalas de tempo muito diferentes — troca de forma, decidida no tático, e troca de cor, decidida no operacional — o que motiva diretamente a estrutura hierárquica adotada neste trabalho, e não apenas a reaproveita por conveniência de modelagem.

3 Processo produtivo

O processo produtivo (Figura 1) inicia-se no recebimento de matérias-primas. Devido à sua perecibilidade, o látex é recebido diariamente e estocado em tanques, enquanto os demais insumos químicos pertencentes à produção são repostos conforme a demanda.

A transformação começa na pré-vulcanização, onde o látex é misturado a agentes químicos para viabilizar a futura elasticidade do produto. A seguir, o composto recebe pigmentos e aditivos de acabamento (perolado, brilhante, fosco), gerando diversas combinações demandadas pelo mercado.

Dimensionado pelo planejamento tático e sequenciado pelo planejamento operacional, o composto alimenta as máquinas de moldagem. Em um processo contínuo, os moldes imergem no fluido, recebem talco, são vulcanizados em estufas e desmoldados mecanicamente.

Por fim, batedores removem o excesso de talco dos balões semiacabados. Os produtos são então empacotados e transferidos para o estoque de produtos acabados, prontos para distribuição.

Este trabalho tem como intuito explorar o processo de tomada de decisão nos planejamentos tático e operacional.




Figura 1 – Fluxograma do processo produtivo

3.1 Planejamento tático

O planejamento tático determina o que, onde, quando e quanto produzir, balanceando estoques e garantindo o atendimento da demanda ao longo do horizonte. A demanda e o estoque são agregados por formato e acabamento dos balões; a segregação por cor, granularidade inferior, não é considerada nesta etapa.

O nível de estoque alvo de cada período é definido em função da demanda futura: o tomador de decisão estabelece quantos períodos à frente o estoque deve cobrir, com

o alvo (de cada combinação de formato e acabamento de balão) assumindo valores que podem variar dinamicamente conforme a demanda (prevista ou passada). Essa cobertura orienta se a produção do período deve repor ou consumir o estoque disponível.

O plano de produção é elaborado em periodicidade semanal, com revisões eventuais conforme a necessidade operacional. As trocas de formas entre balões de diferentes formatos configuram longos tempos de *setup*: no limite mínimo, ocorrem entre turnos de trabalho, mas na prática se dão com intervalos de dias, dado o alto custo de tempo envolvido. A heterogeneidade entre equipamentos é o fator que viabiliza a operação simultânea de diferentes balões: cada máquina pode ser alocada a um formato distinto, permitindo atender o *mix* (a combinação de formatos demandados) sem que todas as máquinas passem por *setup* ao mesmo tempo.

Cada máquina possui taxas de produção e compatibilidades próprias para cada formato e acabamento de balão. A capacidade produtiva pode ser reduzida por ociosidades programadas, decorrentes de manutenções preventivas, reformas ou paradas não planejadas.

O objetivo do modelo de otimização proposto por este trabalho é o de minimizar custos de oportunidade: custos de *setup*, pela produção não realizada durante as trocas, e vendas perdidas, quando a capacidade disponível é insuficiente para atender a demanda. O custo unitário dos balões orienta tanto a priorização do atendimento quanto o sequenciamento das trocas.

Essa lógica de custo de oportunidade é formalizada na função objetivo do modelo de otimização, apresentado na Seção 5.

3.2 Previsão de demanda

A previsão da demanda é um elemento chave do planejamento, pois é a partir dela que se definem a alocação das máquinas, e por consequência as decisões de estocagem e, possivelmente, priorização de perdas por não atendimento de demanda.

No contexto do planejamento tático no problema de produção de balões de látex, a acurácia da previsão é fundamental e depende fortemente de conseguir capturar períodos de sazonalidade ao longo do ano, bem como tendências da empresa e do mercado.

Nessa etapa da modelagem do problema, o objetivo do estudo é explorar métodos e arquiteturas diferentes de previsão de demanda a fim de observar o impacto da acuracidade no planejamento produtivo. O parâmetro α no modelo de otimização, por sua vez, pode ser usado para controlar o nível de estoque e reduzir o impacto do erro dos modelos: melhores acuracidades permitem maior giro de estoque ao longo do ano.

3.3 Planejamento operacional

4 Modelo de demanda

A modelagem da demanda proposta neste trabalho baseia-se em uma abordagem econômica hierárquica *top-down*. O objetivo é isolar os efeitos exógenos e sazonais em níveis agregados de histórico de vendas, onde o sinal estatístico é mais forte e o ruído é menor, e repassar esse aprendizado para os níveis mais granulares na forma de coeficientes *a priori*.

O modelo extrai características (*features*) exógenas e temporais através de múltiplos níveis de agregação e, em seguida, normaliza as vendas para a obtenção de uma demanda base por produto. O *forecast* final é a recombinação dessa base com os efeitos sazonais projetados.

Conjuntos

T	Conjunto de períodos históricos.
I	Conjunto de balões (combinação de formato e acabamento).
F	Conjunto de formatos de balões.
$I_f \subseteq I$	Subconjunto de balões pertencentes ao formato $f \in F$.
K	Conjunto de <i>features</i> exógenas e sazonais.

Parâmetros

y_{it}	Demanda real observada do balão i no período t .
Y_{ft}	Demanda real agregada do formato f no período t .
Y_t	Demanda real global agregada no período t .
X_{kt}	Valor da <i>feature</i> k no período t .
λ	Fator de penalização na transferência de coeficientes.
h	Horizonte futuro de previsão.

Variáveis

$\beta_k^{(0)}$	Coefficiente da <i>feature</i> k no nível global a ser estimado.
$\beta_{fk}^{(1)}$	Coefficiente da <i>feature</i> k para o formato f a ser estimado.
$\beta_{ik}^{(2)}$	Coefficiente da <i>feature</i> k para o balão i a ser estimado.
$\hat{\beta}$	Parâmetros já estimados e fixados na etapa anterior de agregação.
S_{it}	Efeito sazonal/exógeno consolidado para o balão i no período t .
$\tilde{y}_{it}$	Demanda dessazonalizada do balão i no período t .
B_i	Demanda base média do balão i .
$\hat{d}_{i,t+h}$	Previsão final de demanda do balão i para o período futuro $t + h$.

A extração dos efeitos sazonais e exógenos é feita em cascata. O modelo utiliza uma formulação log-linear (multiplicativa) em detrimento de uma abordagem aditiva devido

à natureza da propagação da demanda. Em eventos de forte sazonalidade (final de ano, por exemplo), a demanda agregada pode triplicar. A transformação logarítmica permite que esse comportamento atue como um fator multiplicativo percentual, sendo repassado de forma coerente e proporcional para os níveis inferiores. Caso um modelo aditivo fosse empregado, um incremento absoluto capturado no nível global (um aumento sazonal de 10.000 kg, por exemplo) perderia o sentido ao ser cascadeado para uma combinação específica de formato e acabamento, cuja escala natural de vendas é substancialmente menor. Ademais, a modelagem multiplicativa previne intrinsecamente a projeção de demandas negativas.

Para a estimação destes parâmetros, utiliza-se o algoritmo *Recursive Least Squares* (RLS), que atualiza os coeficientes incrementalmente a cada nova observação minimizando o erro quadrático acumulado.

A estimação inicial, no nível global, ocorre sobre a demanda total consolidada:

$$\hat{\beta}^{(0)} = \arg \min_{\beta} \sum_{t \in T} \left(\ln(Y_t) - \sum_{k \in K} \beta_k X_{kt} \right)^2 \quad (1)$$

No nível de formato, os coeficientes globais $\hat{\beta}_k^{(0)}$ atuam como *priors* para a estimação, e o termo de regularização λ penaliza desvios do comportamento global:

$$\hat{\beta}_f^{(1)} = \arg \min_{\beta} \left(\sum_{t \in T} \left(\ln(Y_{ft}) - \sum_{k \in K} \beta_k X_{kt} \right)^2 + \lambda \sum_{k \in K} (\beta_k - \hat{\beta}_k^{(0)})^2 \right) \quad \forall f \in F \quad (2)$$

No nível de formato-acabamento, por fim, os coeficientes do formato respectivo atuam como *priors* para o balão específico:

$$\hat{\beta}_i^{(2)} = \arg \min_{\beta} \left(\sum_{t \in T} \left(\ln(y_{it}) - \sum_{k \in K} \beta_k X_{kt} \right)^2 + \lambda \sum_{k \in K} (\beta_k - \hat{\beta}_{f,k}^{(1)})^2 \right) \quad \forall f \in F, i \in I_f \quad (3)$$

Com os coeficientes granulares $\hat{\beta}_{ik}^{(2)}$ obtidos, o efeito consolidado para o balão i no período t retorna à escala original:

$$S_{it} = \exp \left(\sum_{k \in K} \hat{\beta}_{ik}^{(2)} X_{kt} \right) \quad \forall i \in I, t \in T \quad (4)$$

A demanda observada é então normalizada pelo efeito consolidado, isolando a demanda base do produto naquele período:

$$\tilde{y}_{it} = \frac{y_{it}}{S_{it}} \quad \forall i \in I, t \in T \quad (5)$$

A demanda base é definida como a média das vendas normalizadas ao longo de todo o horizonte histórico observado $|T|$:

$$B_i = \frac{1}{|T|} \sum_{t \in T} \tilde{y}_{it} \quad \forall i \in I \quad (6)$$

O *forecast* para um período futuro $t+h$ projeta a demanda base multiplicando-a pelos efeitos esperados:

$$\hat{d}_{i,t+h} = B_i \cdot \exp \left(\sum_{k \in K} \hat{\beta}_{ik}^{(2)} X_{k,t+h} \right) \quad \forall i \in I \quad (7)$$

5 Modelo de otimização

Conjuntos

T	Conjunto de períodos.
I	Conjunto de balões.
J	Conjunto de máquinas.
D	Conjunto de dias do horizonte.
$D_t \subseteq D$	Dias pertencentes ao período $t \in T$.

Parâmetros

d_{it}	Demanda do balão i no período t (kg).
c_i	Custo unitário do balão i (R\$/kg).
p_{ij}	Produtividade do balão i na máquina j (kg/hora).
b_{jd}	Horas produtivas disponíveis da máquina j no dia d .
t_j^s	Tempo de <i>setup</i> na máquina j (horas).
α	Número de períodos futuros de demanda de estoque de segurança.
I_i^0	Estoque do balão i no início do horizonte, $t = 0$ (kg).

Variáveis

$s_{ijd} \in \{0, 1\}$	1 se a máquina j produz o balão i no dia d .
$\delta_{ijd} \in \{0, 1\}$	1 se ocorre <i>setup</i> para o balão i na máquina j no dia d .
$I_{it} \geq 0$	Estoque do balão i ao final do período t (kg).
$l_{it} \geq 0$	Venda perdida do balão i no período t (kg).
$z_{jd} \in \{0, 1\}$	1 se a máquina j está parada no dia d .

Minimizar

$$Z = \sum_{i \in I} \sum_{j \in J} \sum_{d \in D} c_i p_{ij} t_j^s \delta_{ijd} + \sum_{i \in I} \sum_{t \in T} c_i l_{it} \quad (8)$$

Sujeito a

$$\sum_{i \in I} s_{ijd} \leq 1 \quad \forall j \in J, d \in D \quad (9)$$

$$\delta_{ijd} \geq s_{ijd} - s_{ij,d-1} \quad \forall i \in I, j \in J, d \in D \quad (10)$$

$$\sum_{i \in I} s_{ijd} \leq 1 - z_{jd} \quad \forall j \in J, d \in D \quad (11)$$

$$I_{i,t-1} + \sum_{d \in D_t} \sum_{j \in J} (b_{jd} - t_j^s \delta_{ijd}) s_{ijd} p_{ij} = I_{it} + d_{it} - l_{it} \quad \forall i \in I, t \in T \quad (12)$$

$$I_{it} \geq \sum_{k=1}^{\alpha} d_{i,t+k} \quad \forall i \in I, t \in T \quad (13)$$

A função objetivo (8) minimiza o custo total de oportunidade: o custo de setup é mensurado pela receita perdida durante o tempo de troca — produção que deixa de ocorrer, ponderando o custo unitário c_i e a produtividade p_{ij} da máquina — e o segundo termo penaliza as vendas não atendidas, multiplicando o custo unitário pela quantidade de kg de balões perdidos l_{it} . Paradas programadas não entram diretamente no objetivo, mas restringem os dias disponíveis de produção.

Cada máquina produz no máximo um tipo de balão por dia ativo (11), podendo ficar sem configuração quando parada. Isso permite que, dentro de um mesmo período, a máquina produza balões diferentes em dias distintos. A restrição (10) detecta mudanças de configuração dia a dia: δ_{ijd} é ativado sempre que s_{ijd} passa de inativo para ativo, cobrindo tanto trocas de balão quanto retomadas após parada. O setup ocorre no primeiro dia de cada configuração e consome t_j^s horas desse dia, reduzindo a produção.

A restrição (11) garante que cada máquina opere no máximo um balão por dia e fique inativa quando parada ($z_{jd} = 1$) ou com parada programada ($b_{jd} = 0$).

O balanço de estoque (12) é formulado de forma recursiva no nível de período: o estoque anterior mais a produção acumulada equivale ao estoque corrente mais a demanda, com a venda perdida l_{it} absorvendo o déficit. A produção efetiva no dia d é $(b_{jd} - t_j^s \delta_{ijd}) s_{ijd} p_{ij}$: quando há setup no dia de ativação ($\delta_{ijd} = 1$), as horas de troca são descontadas das horas disponíveis b_{jd} , reduzindo a quantidade produzida nesse dia. A restrição (13) impõe que o estoque ao final de cada período cubra integralmente a demanda dos α períodos seguintes; quando $\alpha = 0$, a restrição é inativa e nenhum nível mínimo é exigido.

Referências

- ANTHONY, R. N. *Planning and Control Systems: A Framework for Analysis*. Boston: Division of Research, Graduate School of Business Administration, Harvard University, 1965.
- BITRAN, G. R.; HAX, A. C. On the design of hierarchical production planning systems. *Decision Sciences*, v. 8, n. 1, p. 28–55, 1977.
- BITRAN, G. R.; YANASSE, H. H. Computational complexity of the capacitated lot size problem. *Management Science*, v. 28, n. 10, p. 1174–1186, 1982.
- BRAHIMI, N. et al. Single-item dynamic lot-sizing problems: An updated survey. *European Journal of Operational Research*, v. 263, n. 3, p. 838–863, 2017.
- BRAHIMI, N. et al. Single item lot sizing problems. *European Journal of Operational Research*, v. 168, n. 1, p. 1–16, 2006.
- BUSCHKÜHL, L. et al. Dynamic capacitated lot-sizing problems: A classification and review of solution approaches. *OR Spectrum*, v. 32, p. 231–261, 2010.
- CAMARGO, V. C. B.; TOLEDO, F. M. B.; ALMADA-LOBO, B. Three time-based scale formulations for the two-stage lot sizing and scheduling in process industries. *Journal of the Operational Research Society*, v. 63, p. 1613–1630, 2012.
- CAMARGO, V. C. B.; TOLEDO, F. M. B.; ALMADA-LOBO, B. Hops — hamming-oriented partition search for production planning in the spinning industry. *European Journal of Operational Research*, v. 234, n. 2, p. 266–277, 2014.
- CHEN, W.-H.; THIZY, J.-M. Analysis of relaxations for the multi-item capacitated lot-sizing problem. *Annals of Operations Research*, v. 26, p. 29–72, 1990.
- COPIL, K. et al. Simultaneous lotsizing and scheduling problems: A classification and review of models. *OR Spectrum*, v. 39, n. 1, p. 1–64, 2017.
- DREXL, A.; KIMMS, A. Lot sizing and scheduling — survey and extensions. *European Journal of Operational Research*, v. 99, n. 2, p. 221–235, 1997.
- FERREIRA, D.; MORABITO, R.; RANGEL, S. Solution approaches for the soft drink integrated production lot sizing and scheduling problem. *European Journal of Operational Research*, v. 196, n. 2, p. 697–706, 2009.
- FERREIRA, D.; MORABITO, R.; RANGEL, S. Relax and fix heuristics to solve one-stage one-machine lot-scheduling models for small-scale soft drink plants. *Computers & Operations Research*, v. 37, n. 4, p. 684–691, 2010.
- FLEISCHMANN, B.; MEYR, H. The general lotsizing and scheduling problem. *OR Spektrum*, v. 19, p. 11–21, 1997.
- GUIMARÃES, L.; KLABJAN, D.; ALMADA-LOBO, B. Modeling lotsizing and scheduling problems with sequence dependent setups. *European Journal of Operational Research*, v. 239, n. 3, p. 644–662, 2014.

- GÜNTHER, H.-O.; GRUNOW, M.; NEUHAUS, U. Realizing block planning concepts in make-and-pack production using milp modelling and sap apo. *International Journal of Production Research*, v. 44, n. 18-19, p. 3711–3726, 2006.
- HAASE, K. Capacitated lot-sizing with sequence dependent setup costs. *OR Spektrum*, v. 18, p. 51–59, 1996.
- HAX, A. C.; MEAL, H. C. Hierarchical integration of production planning and scheduling. In: *TIMS Studies in Management Science, Vol. 1: Logistics*. New York: North-Holland/American Elsevier, 1975.
- JANS, R.; DEGRAEVE, Z. Modeling industrial lot sizing problems: A review. *International Journal of Production Research*, v. 46, n. 6, p. 1619–1643, 2008.
- KARIMI, B.; Fatemi Ghomi, S. M. T.; WILSON, J. M. The capacitated lot sizing problem: A review of models and algorithms. *Omega*, v. 31, n. 5, p. 365–378, 2003.
- SOX, C. R.; GAO, Y. The capacitated lot sizing problem with setup carry-over. *IIE Transactions*, v. 31, n. 2, p. 173–181, 1999.
- STADTLER, H. Supply chain management and advanced planning — basics, overview and challenges. *European Journal of Operational Research*, v. 163, n. 3, p. 575–588, 2005.
- SUERIE, C.; STADTLER, H. The capacitated lot-sizing problem with linked lot sizes. *Management Science*, v. 49, n. 8, p. 1039–1054, 2003.
- TOLEDO, C. F. M. et al. A memetic framework for solving the lot sizing and scheduling problem in soft drink plants. In: CHIONG, R.; WEISE, T.; MICHALEWICZ, Z. (Ed.). *Variants of Evolutionary Algorithms for Real-World Applications*. Berlin, Heidelberg: Springer, 2012. p. 65–93.
- WAGNER, H. M.; WHITIN, T. M. Dynamic version of the economic lot size model. *Management Science*, v. 5, n. 1, p. 89–96, 1958.

Apêndice

Exemplo numérico: previsão de demanda

Os dados foram uniformemente escalados por um fator aleatório para descaracterizar sua grandeza; as relações relativas são preservadas e as análises permanecem válidas. Consideram-se três formatos: f_1 , com dois acabamentos ($I_{f_1} = \{i_{11}, i_{12}\}$); f_2 e f_3 , com acabamento único ($I_{f_2} = \{i_{21}\}$, $I_{f_3} = \{i_{31}\}$).

O produto i_{31} representa $\approx 37\%$ do volume total; i_{21} é um produto de nicho com sazonalidade de primavera, oposta ao padrão de mercado. O horizonte de estimação compreende 12 períodos mensais; os 5 períodos subsequentes constituem o conjunto de teste. As *features* são indicadores binários mensais ($X_{kt} = \mathbf{1}[\text{mês}(t) = k]$, $k \in \{1, \dots, 12\}$).

A Tabela 2 apresenta a demanda em quatro meses: janeiro (baixa estação global), abril (pico de i_{21}), setembro (pico global) e dezembro.

Tabela 2 – Demanda observada (kg) – hierarquia de agregação, meses selecionados

	Jan	Abr	Set	Dez
i_{21}	475	2.091	807	440
i_{11}	11.161	10.455	18.425	10.065
i_{12}	8.201	8.697	13.348	9.829
$Y_{f_1 t}$ (Formato f_1)	19.362	19.152	31.773	19.894
Y_t (Global)	283.116	341.760	474.871	356.801

Na estimação global ($\hat{\beta}^{(0)}$), o sistema da Equação (1) é exatamente identificado com 12 observações e 12 *features* ortogonais: $\hat{\beta}_k^{(0)} = \ln(Y_{[k]})$, onde $Y_{[k]}$ é a demanda global do mês k .

Tabela 3 – Coeficientes globais $\hat{\beta}_k^{(0)} = \ln(Y_{[k]})$

Mês	$\hat{\beta}^{(0)}$	$e^{\hat{\beta}^{(0)}}$	Mês	$\hat{\beta}^{(0)}$	$e^{\hat{\beta}^{(0)}}$
Jan	12,554	283.116	Jul	12,756	346.492
Fev	12,507	270.087	Ago	12,904	401.897
Mar	12,777	353.971	Set	13,071	474.871
Abr	12,742	341.760	Out	13,159	518.282
Mai	12,818	368.521	Nov	13,054	466.601
Jun	12,925	410.416	Dez	12,785	356.801

O pico global ocorre em outubro ($e^{13,159} \approx 518$ mil) e o vale em fevereiro ($e^{12,507} \approx 270$ mil), razão pico/vale de 1,92.

Na estimação por formato ($\hat{\beta}^{(1)}$), com $\lambda = 1$ e *features* ortogonais:

$$\hat{\beta}_{fk}^{(1)} = \frac{\ln(Y_{f[k]}) + \hat{\beta}_k^{(0)}}{2}$$

Tabela 4 – Coeficientes de formato: global vs. f_1 vs. f_2

Mês	$\hat{\beta}^{(0)}$	Formato f_1		Formato f_2	
		$\hat{\beta}_{f_1}^{(1)}$	$e^{\hat{\beta}_{f_1}^{(1)}}$	$\hat{\beta}_{f_2}^{(1)}$	$e^{\hat{\beta}_{f_2}^{(1)}}$
Jan	12,554	11,213	74.455	9,359	11.613
Abr	12,742	11,301	81.043	10,194	26.703
Set	13,071	11,719	122.467	9,883	19.624
Dez	12,785	11,342	84.014	9,436	12.509

Para f_1 , a razão entre os efeitos sazonais de abril e setembro é 0,66, consistente com o padrão global. Para f_2 , essa razão é 1,36: abril supera setembro em 36%.

Na estimação por produto ($\hat{\beta}^{(2)}$), aplicando o mesmo mecanismo a partir do prior de formato:

$$\hat{\beta}_{ik}^{(2)} = \frac{\ln(y_{i[k]}) + \hat{\beta}_{fk}^{(1)}}{2}$$

Tabela 5 – Coeficientes de produto – cascata de estimação (4 meses selecionados)

Mês	$\hat{\beta}_{f_1}^{(1)}$	$\hat{\beta}_{i_{11}}^{(2)}$	$\hat{\beta}_{i_{12}}^{(2)}$	$\hat{\beta}_{f_2}^{(1)}$	$\hat{\beta}_{i_{21}}^{(2)}$
Jan	11,213	10,267	10,113	9,359	7,762
Abr	11,301	10,278	10,186	10,194	8,920
Set	11,719	10,770	10,609	9,883	8,289
Dez	11,342	10,280	10,268	9,436	7,762

Para i_{21} , o coeficiente máximo ocorre em abril, ao contrário dos demais produtos.

Os coeficientes $\hat{\beta}_i^{(2)}$ determinam S_{it} (Equação (4)); a dessazonalização $\tilde{y}_{it} = y_{it}/S_{it}$ conduz à demanda base B_i (Equação (6)), e o *forecast* final é $\hat{d}_{i,t+h} = B_i \cdot S_{i,t+h}$ (Equação (7)).

Tabela 6 – Efeito sazonal S_{it} (kg) e demanda base B_i por nível

	i_{11}	i_{12}	i_{21}	i_{31}
S_{it} – Jan	28.746	24.642	2.348	114.149
S_{it} – Abr	29.082	26.525	7.474	158.842
S_{it} – Set	47.573	40.493	3.977	221.173
S_{it} – Dez	29.122	28.774	2.348	173.871
B_i (Nível 0)	0,037	0,028	0,003	0,365
B_i (Nível 1)	0,145	0,110	0,049	0,604
B_i (Nível 2)	0,380	0,331	0,218	0,777

Para i_{11} , setembro supera abril em 64% (47.573/29.082); para i_{21} , a relação é inversa – abril supera setembro em 88% (7.474/3.977).

A Tabela 7 compara os três níveis de agregação para i_{21} , produto com maior divergência entre sazonalidade global e individual; a Tabela 8 traz o erro percentual correspon-

dente a cada nível, incluindo o MAPE (*Mean Absolute Percentage Error*, erro percentual absoluto médio) agregado dos 5 períodos de teste.

Tabela 7 – Previsão vs. demanda real – i_{21} (kg), 5 períodos de teste

Período	Real	Nível 0	Nível 1	Nível 2
Jan	469	748	567	513
Fev	936	712	807	890
Mar	1.319	935	1.101	1.241
Abr	2.456	902	1.307	1.632
Mai	2.252	973	1.274	1.514

Tabela 8 – Erro percentual de previsão – i_{21} , por nível de agregação

Período	Nível 0	Nível 1	Nível 2
Jan	+59%	+21%	+9%
Fev	−24%	−14%	−5%
Mar	−29%	−16%	−6%
Abr	−63%	−47%	−34%
Mai	−57%	−43%	−33%
MAPE	46,5%	28,3%	17,3%

Em abril, o Nível 0 projeta 902 kg frente a 2.456 kg reais; como o modelo global concentra o pico no outono, i_{21} é subestimado sistematicamente na primavera. O Nível 2 reduz esse erro de −63% para −34%.

Tabela 9 – MAPE (%) por produto e nível de agregação – 5 períodos de teste

Produto	Nível 0	Nível 1	Nível 2
i_{31} (f_3)	21,8	23,9	24,8
i_{11} (f_1)	21,3	20,9	21,3
i_{12} (f_1)	29,0	27,1	29,4
i_{21} (f_2)	46,5	28,3	17,3

Por representar $\approx 37\%$ da demanda agregada, i_{31} domina os coeficientes globais: o Nível 0 é sua melhor aproximação e granularidade adicional penaliza por sobreajuste. Para i_{11} e i_{12} , o Nível 1 traz melhora marginal. Para i_{21} – cujo volume é cerca de 150 vezes inferior ao de i_{31} e cuja sazonalidade diverge do mercado – a cascata reduz o MAPE de 46,5% para 17,3%.